

UNIVERSITI MALAYA
UNIVERSITI MALAYA

PEPERIKSAAN IJAZAH SARJANA MUDA SAINS KOMPUTER
EXAMINATION FOR THE DEGREE OF BACHELOR OF COMPUTER SCIENCE

SESI AKADEMIK 2022/2023 : SEMESTER II
ACADEMIC SESSION 2022/2023 : SEMESTER II


WIA1006 : Pembelajaran Mesin
Machine Learning

Julai 2023
July 2023

Masa: 2 jam
Time: 2 hours

ARAHAN KEPADA CALON:
INSTRUCTIONS TO CANDIDATES:

Calon dikehendaki menjawab **SEMUA** soalan.
Answer **ALL** questions.




(Kertas soalan ini mengandungi 5 soalan dalam 8 halaman yang dicetak)
(This question paper consists of 5 questions on 8 printed pages)

1. Seorang ahli sains komputer ingin menggunakan rangkaian neural buatan (ANN) untuk secara otomatis menentukan spesies burung finch Galapagos (burung subfamili Geospizinae) dalam imej menggunakan pengukuran berikut: Panjang paruh, ketinggian paruh, diameter mata, panjang kepala, dan panjang badan. Diberikan lokasi tempat gambar diambil, spesies yang mungkin adalah 1. Large Ground Finch *Geospiza magnirostris*, 2. Medium Ground Finch *Geospiza fortis*, 3. Small Tree Finch *Camarhynchus parvulus* dan 4. Green Warber-Finch *Certhidea olivacea*. Beliau mempunyai pangkalan data yang mempunyai 500 ratus gambar berlabel untuk spesies ini bagi melatih ANN-nya

A computer scientist wishes to use artificial neural network (ANN) to automatically determine the species of Galapagos finches (birds of the subfamily Geospizinae) in images using the following measurements: Beak length, beak height, eye diameter, head length and body length.

*Given the location where the pictures were taken, the possible species are 1. Large Ground Finch *Geospiza magnirostris*, 2. Medium Ground Finch *Geospiza fortis*, 3. Small Tree Finch *Camarhynchus parvulus* and 4. Green Warber-Finch *Certhidea olivacea*. He has a database of 500 labelled images of these species to train his ANN.*



Nyatakan input anda tentang aspek reka bentuk ANN berikut. Berikan pilihan untuk aspek reka bentuk tersebut dan justifikasikan pilihan anda.

Provide your input on the following design aspect of this ANN. That is, give choices for these design aspects and justify your choices.

- a) Berapakah unit input yang diperlukan oleh ANN?

How many input units should the ANN have?

(4 markah/marks)

- b) Berapakah unit output yang diperlukan oleh ANN?

How many output units should the ANN have?

(4 markah/marks)

- c) Adakah ANN tersebut perlu menggunakan unit tersembunyi atau tidak?

Should the ANN use hidden units or not?

(4 markah/marks)

- d) Adakah ANN tersebut perlu menggunakan sambungan *feedforward*, sambungan berulang, kedua-duanya atau tidak sama sekali?

Should the ANN use feedforward connection, recurrent connection, both or neither?

(4 markah/marks)

- e) Apakah fungsi pengaktifan yang perlu digunakan oleh neuron?

What activation functions should the neuron use?

(4 markah/marks)

- f) Apakah mekanisme pembelajaran yang perlu digunakan oleh ANN?

What learning mechanisms should the ANN use?

(5 markah/marks)

2. Anggapkan kita mempunyai fungsi untuk dioptimumkan

$$f(x) = x^3 - 60x^2 + 900x + 100$$

di mana x terhad pada 0 hingga 31. Kita ingin memaksimumkan fungsi $f(x)$ (optimum adalah $x = 10$). Dengan menggunakan perwakilan binari, kita boleh mewakili x menggunakan lima digit binari seperti dalam jadual kromosom di bawah:

Kromosom	Rentetan Binari
P ₁	11100
P ₂	01110
P ₃	10111
P ₄	00100

Assume we have a function to optimize:

$$f(x) = x^3 - 60x^2 + 900x + 100$$

where x is constrained to 0 to 31. We wish to maximize $f(x)$ (the optimal is $x = 10$). Using a binary representation, we can represent x using five binary digits as in the chromosomes table below:

Chromosome	Binary String
P ₁	11100
P ₂	01110
P ₃	10111
P ₄	00100

- a) Jika P₂ dan P₃ dipilih sebagai ibu bapa dan kita menggunakan crossover satu titik, tunjukkan anak-anak yang dihasilkan, C₁ dan C₂. Gunakan penutupan silang 11000. Lakukan perkara yang sama dengan menggunakan P₁ dan P₄ dengan titik persilangan 2 dan ciptakan C₃ dan C₄. Berikan jawapan anda dalam format jadual seperti contoh berikut:

If P₂ and P₃ are chosen as parents and we apply one point crossover, show the resulting children, C₁ and C₂. Use a crossover mask 11000. Do the same using P₁ and P₄ with a crossover point of 2 and create C₃ and C₄. Provide your answer in a table format as the following example:

Chromosome	Binary String
C ₁	
C ₂	
C ₃	
C ₄	

(8 markah/marks)

- b) Hitung nilai x dan $f(x)$ untuk C₁, C₂, C₃, C₄. Berikan jawapan anda dalam format jadual seperti contoh berikut:

Calculate the value of x and $f(x)$ for C₁, C₂, C₃, C₄. Provide your answer in a table format as the following example:

Chromosome	Binary String	x	$f(x)$
C ₁			
C ₂			
C ₃			
C ₄			

(8 markah/marks)

3. Anggapkan anda sedang membina model SVM pada data X . Data X boleh mengandungi kesalahan, di mana anda tidak boleh terlalu mempercayai sebarang titik data khusus. Sekarang bayangkan bahawa anda ingin membina model SVM yang mempunyai fungsi kernel kuadratik dengan darjah polinomial 2 yang menggunakan pembolehubah Slack C sebagai salah satu *hyperparameter*.

Suppose you are building an SVM model on data X . The data X can be error-prone which means that you should not trust any specific data point too much. Now think that you want to build an SVM model which has a quadratic kernel function of polynomial degree 2 that uses Slack variable C as one of its hyperparameters.

- a) Apa yang akan berlaku apabila anda menggunakan nilai C yang sangat besar ($C > \text{infinity}$) dan apa yang akan berlaku apabila C sangat kecil ($C \sim 0$)? Terangkan jawapan anda.

What would happen when you use a very large value of C ($C > \text{infinity}$) and what happens when the C is very small ($C \sim 0$)? Explain your answer.

(6 markah/marks)

- b) Terangkan kesan yang berlaku sekiranya kita mengubah hyperparameter ini dalam SVM iaitu *regularization* dan *tolerance* parameter.

Explain the impact that occurs if we change these hyperparameters in SVM, namely the regularization and tolerance parameters.

(3 markah/marks)

4. Dalam tugas makmal 1, anda telah membina sebuah model regresi bagi menjangkakan harga sesebuah rumah berdasarkan beberapa ciri yang diberikan seperti saiz rumah, bilangan bilik tidur, status perabot dan lain-lain.

In labwork 1, you have developed a regression model to predict the housing price based on few features given such as the size of the house, no of bedrooms, furnishing status, etc.

- a) Berdasarkan tugas tersebut, bina sebuah carta alir bagi model jangkaan yang telah dibina. Nyatakan fungsi setiap blok dalam carta alir tersebut.

Based on the task, build a flowchart for the developed prediction model. State the function of each block in the flowchart.

(10 markah/marks)

- b) Katakan anda mempunyai $m=4$ biji rumah, dan setiap rumah mempunyai data keluasan dan bilangan bilik tidur di mana ianya boleh digunakan untuk menjangkakan harga rumah tersebut. Dataset bagi ciri-ciri yang dinyatakan adalah seperti berikut:

Suppose you have $m=4$ houses, and each house has area and number of bedrooms which can be used to predict the house price. A dataset of the features is as follows:

Price	No of bedrooms	Sqft_Area
490000	1	880
630000	3	1930
640000	4	1940
570000	3	1350

Anda ingin menggunakan regresi polynomial untuk menjangkakan harga rumah daripada data bilangan bilik tidur dan keluasan kawasan. Secara konkrit, anda ingin menyesuaikan model dalam bentuk:

$$h_{\theta}(x) = \theta_0 + \theta_1(x_1) + \theta_2(x_2)$$

di mana x_1 adalah bilangan bilik tidur dan x_2 merupakan keluasan kawasan. Selanjutnya, anda merancang untuk menggunakan penskalaan ciri (scaling) dan normalisasi min (mean normalization) untuk kedua-dua ciri. Apakah ciri yang dinormalisasi x_{24} (i.e. untuk data Latihan ke empat)?

You'd like to use polynomial regression to predict a house price from its numbers of bedrooms and sqft_area. Concretely, suppose you wish to fit a model of the form:

$$h_{\theta}(x) = \theta_0 + \theta_1(x_1) + \theta_2(x_2)$$

where x_1 is the number of bedrooms and x_2 is sqft_area. Further you plan to use both feature scaling (dividing by the max-min, or range, of a feature) and mean normalization. What is the normalized feature x_{24} (i.e. for the fourth training data)?

(10 markah/marks)

c) Apakah perbezaan di antara *local minima* dan *global minima gradient descent*?

What is the difference between *local minima* and *global minima gradient descent*?

(5 markah/marks)

5. Jawab soalan berikut:

Answer the following questions:

- a) Klasifier Naïve Bayes adalah algoritma pembelajaran mesin yang diawasi, digunakan untuk tugas pengelasan. Dikira bahawa 50% daripada e-mel adalah e-mel spam. Beberapa perisian telah digunakan untuk menyaring e-mel spam

ini sebelum sampai ke peti masuk anda. Jenama tertentu perisian mendakwa bahawa ia dapat mengesan 99% e-mel spam, dan kebarangkalian positif palsu (e-mel bukan spam yang dikesan sebagai spam) adalah 5%. Sekiranya satu e-mel dikesan sebagai spam, apakah kebarangkalian bahawa ia sebenarnya bukan e-mel spam?

The Naïve Bayes classifier is a supervised machine learning algorithm, which is used for classification tasks. It is estimated that 50% of emails are spam emails. Some software has been applied to filter these spam emails before they reach your inbox. A certain brand of software claims that it can detect 99% of spam emails, and the probability for a false positive (a non-spam email detected as spam) is 5%. Now if an email is detected as spam, then what is the probability that it is in fact a non-spam email?
(10 markah/marks)

- b) Analisa Komponen Prinsipal (PCA) adalah satu kaedah statistik untuk mengenal pasti corak di dalam data. Ia juga boleh digunakan untuk memadatkan data melalui pengurangan dimensi. Senaraikan dan terangkan langkah-langkah yang diperlukan untuk melakukan PCA ke atas data yang diberi di dalam Jadual 1.

Principal component analysis (PCA) is a statistical method for identifying patterns in data. It can also be used to compress data via dimensionality reduction. Specify and explain the steps needed to perform PCA on a set of data provided in Table 1.

x	y
2.5	2.4
0.5	0.7
2.2	2.9
1.9	2.2
3.1	33.0
2.3	2.7
2.1	6
1.1	1
1.5	1.6
1.1	0.9

(10 markah/marks)

c) Apakah fungsi code Python berikut dalam PCA?

What is the function of the following Python coding in PCA?

```
import numpy as np

x = np.array([2.5, 0.5, 2.2, 1.9, 3.1, 2.3, 2.1, 1.1, 1.1, 1.5])
y = np.array([2.4, 0.7, 2.9, 2.2, 3.0, 2.7, 6.0, 1.0, 1.6, 0.9])

x_standardized = (x - np.mean(x)) / np.std(x)
y_standardized = (y - np.mean(y)) / np.std(y)
```

(5 markah/marks)

TAMAT
END