

UNIVERSITI MALAYA
UNIVERSITI MALAYA

PEPERIKSAAN IJAZAH SARJANA MUDA SAINS KOMPUTER
EXAMINATION FOR THE DEGREE OF BACHELOR OF COMPUTER SCIENCE

SESI AKADEMIK 2023/2024 : SEMESTER II
ACADEMIC SESSION 2023/2024 : SEMESTER II

WIA1006/WID3006 : Pembelajaran Mesin
Machine Learning

Jun/Julai 2024
June/July 2024

Masa: 2 jam
Time: 2 hours

ARAHAN KEPADA CALON:
INSTRUCTIONS TO CANDIDATES:

Calon dikehendaki menjawab **SEMUA** soalan (50 markah).
Answer **ALL** questions (50 marks).

Penggunaan Kalkulator adalah **DIBENARKAN**.
The usage of calculator is **ALLOWED**.

(Kertas soalan ini mengandungi 5 soalan dalam 9 halaman yang dicetak)
(This question paper consists of 5 questions on 9 printed pages)

SOALAN 1/QUESTION 1

a) Pemasangan berlebihan adalah masalah biasa di dalam Pembelajaran Mesin. Pohon keputusan juga mengalami masalah ini. Pemasangan berlebihan terjadi apabila sesuatu model belajar data latihan dengan terlalu baik sehingga menarik kerawakan dan variasi naik turun di dalam data dan bukannya corak yang tersembunyi. Di dalam Pohon keputusan, pemasangan berlebihan akan menyebabkan Pohon yang terlalu kompleks yang menghasilkan keputusan yang baik pada data latihan tetapi mempunyai generalisasi yang buruk pada data yang baru.

Berikan **DUA (2)** solusi atau pendekatan yang boleh diberikan untuk mengelakkan atau menyelesaikan masalah pemasangan terlebih ini.

Overfitting is very common in Machine Learning. Decision Tree is also possible to be overfitted. Overfitting occurs when a model learns the training data too well, capturing noise or random fluctuations in the data rather than the underlying pattern. In decision trees, overfitting can lead to overly complex trees that perform well on the training data but generalize poorly to unseen data.

Give **TWO (2)** solutions or approaches that can be used to avoid or solve this overfitting problem in the Decision Tree.

(2 markah/marks)

b) Entropi adalah suatu ukuran ketidakaturan atau ketidakpastian dalam suatu sistem. Dalam teori informasi, ia sering digunakan untuk mengukur jumlah informasi yang terkandung dalam suatu pesan atau pembolehubah rawak. Mari kita pertimbangkan lemparan syiling biasa yang sederhana. Katakanlah kita mempunyai syiling yang condong, di mana kebarangkalian mendarat dengan kepala adalah $p = 0.6$ dan kebarangkalian mendarat dengan ekor adalah q yang berlawanan.

Entropy is a measure of disorder or uncertainty in a system. In information theory, it is often used to quantify the amount of information contained in a message or a random variable. Let's consider a simple biased coin flip. Suppose we have a coin that is biased, such that the probability of landing heads is $p = 0.6$ and the probability of landing tails is the opposite q .

i) Kirakan kebarangkalian mendarat dengan ekor q .

Calculate the probability of landing tails q .

(1 markah/mark)

ii) Kirakan entropi (S), di mana formula bagi entropi adalah:

Calculate the entropy (S), given the formula for entropy is:

$$\text{Entropy}(S) = -p_1 \log_2(p_1) - p_0 \log_2(p_0)$$

(4 markah/marks)

iii) Terangkan apakah makna nilai yang telah anda kirakan di atas.

Explain what it means by the value you calculated above.

(1 markah/mark)

c) ID3 (Iterative Dichotomiser 3) adalah algoritma yang popular digunakan untuk membina pokok keputusan, yang merupakan jenis model prediktif yang digunakan dalam pembelajaran mesin. Algoritma ini telah dibangunkan oleh Ross Quinlan pada tahun 1979. Terangkan **DUA (2)** ciri penting ID3.

*ID3 (Iterative Dichotomiser 3) is a popular algorithm used for building decision trees, which are a type of predictive model used in machine learning. The algorithm was developed by Ross Quinlan in 1979. Describe **TWO (2)** important characteristics of ID3.*

(2 markah/marks)

SOALAN 2/QUESTION 2

Pertimbangkan sebuah Algoritma Genetik (GA) yang digunakan untuk menyelesaikan masalah optimisasi sederhana untuk memaksimumkan sebuah fungsi, di mana x adalah nombor sebenar dalam julat $[0, 6]$. Andaikan saiz populasi adalah 10, dengan kebarangkalian kross-over sebanyak 0.8, dan kebarangkalian mutasi sebanyak 0.1.

Consider a Genetic Algorithm (GA) being used to solve a simple optimization problem of maximizing a function, where x is a real number in the range $[0, 6]$. Assume a population size of 10, a crossover probability of 0.8, and a mutation probability of 0.1.

a) Terangkan proses pengamatan dalam GA dan terangkan bagaimana ia menghasilkan populasi awal.

Describe the initialization process in the GA and explain how it generates the initial population.
(2 markah/marks)

b) Apakah fungsi kecergasan bagi masalah ini dan terangkan bagaimana ia menilai kualiti penyelesaian.

What is the fitness function for this problem and explain how it evaluates the quality of solutions.
(2 markah/marks)

c) Terangkan proses pemilihan, silang pilih, dan mutasi menggunakan contoh di atas.

Describe the process of selection, crossover, and mutation using the example above.

(3 markah/marks)

d) Nyatakan **TIGA (3)** kriteria penamatan yang boleh digunakan untuk menghentikan GA.

*State **THREE (3)** termination criteria that could be used to stop the GA.*

(3 markah/marks)

SOALAN 3/QUESTION 3

Anda sedang melawat sebuah bandar A di negara Z. Di bandar ini, ibu bapa dalam komuniti menggalakkan anak-anak mereka untuk membaca dengan membayar mereka mengikut bilangan jam yang mereka habiskan untuk membaca buku. Jumlah bayaran berbeza bergantung kepada ibu bapa. Anda telah membuat beberapa pengumpulan data dengan melakukan tinjauan cepat terhadap 10 ibu bapa dan berapa banyak mereka membayar anak-anak mereka untuk membaca. Data diberikan seperti di bawah dalam Jadual 1. Dalam set data di bawah, X (jam yang dihabiskan untuk membaca) adalah vektor ciri dan y (bayaran dalam \$) adalah output sasaran.

You are visiting town A in country Z. In this town, the parents in the community are encouraging their children to read by paying them according to the hours they spend reading books. The amount of pay varies depending on the parent. You've made some data collection by doing a quick survey of 10 parents and how much they pay their children to read. The data is given below in Table 1. In the dataset below, X (hours spent reading) is the feature vector and y (pay in \$) are the target output.

Jadual 1. Bilangan jam pembacaan dan bayarannya
Table 1. The number of hours reading and its payment.

X (hours read)	Y (pay in \$)
2.5	2.4
0.5	0.7
2.2	2.9
1.9	2.2
3.1	3.0
2.3	2.7
2	1.6
1	1.1
1.5	1.6
1.1	0.9

a) Kira kovarians $Cov(X, Y)$. Formula untuk mengira kovarians antara pembolehubah x dan y diberikan seperti berikut.

Calculate the covariance $Cov(X, Y)$. The formula for computing the covariance between variable x and y is given as follows.

$$cov(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{(n - 1)}$$

Di mana X_i adalah sampel ke- i ciri X , $\bar{X}$ adalah purata ciri X , n adalah jumlah keseluruhan sampel dalam set data.

Where X_i is the i th sample of feature X , $\bar{X}$ is the mean of feature X , n is the total number of samples in the dataset.

(5 markah/marks)

b) Apakah perbezaan antara korelasi dan kovarians? Berikan contoh menggunakan dua pembolehubah X dan Y . Mengapa kita mengira kovarians bukannya korelasi untuk PCA?

What is the difference between correlation and covariance? Give an example using two variables X and Y . Why are we calculating covariance instead of correlation for PCA?

(3 markah/marks)

c) Nilai-nilai eigen bagi masalah ini telah dikira dan diberikan sebagai.

The eigenvalues for this problem has been calculated and is given as

$$\Lambda = \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix} = \begin{pmatrix} 0.490 \\ 1.284 \end{pmatrix}$$

Nilai eigen yang manakah lebih penting dan mengapa?

Which eigenvalues are more important and why?

(2 markah/marks)

SOALAN 4/QUESTION 4

John mempunyai maklumat 4 rumah, iaitu saiz dalam ribu kaki persegi, bilangan bilik dan harga dalam juta Ringgit Malaysia, dan dibentangkan dalam jadual di bawah:

John has the information of 4 houses, i.e. size in thousand square feet, number of rooms and price in million Ringgit Malaysia, and presented in the table below:

Rumah <i>House</i>	Saiz (ribu kaki persegi) <i>Size (thousand square feet)</i>	Bilik <i>Room</i>	Harga (Juta Ringgit Malaysia) <i>Price (million Ringgit Malaysia)</i>
A	1.3	3	1.6
B	1.8	4	2.5
C	1.1	2	0.8
D	1.5	4	1.9

John mengandaikan bahawa rumah boleh dikumpulkan kepada 2 kelompok, P dan Q, menggunakan algoritma K-Means dengan jarak Euclidean. Selain itu, beliau juga menganggap pusat gugusan awal adalah (1, 1, 1) dan (3, 3, 3) masing-masing.

John assumes that the houses can be grouped into 2 clusters, P and Q, using K-Means algorithm with Euclidean distance. Apart from this, he also assumes the initial cluster centers are (1, 1, 1) and (3, 3, 3) respectively.

a) Berapakah nilai K bagi kes ini?

What is the value of K for this case?

(1 markah / mark)

b) Dengan andaian yang John buat ini, tentukan rumah yang tergolong dalam kedua-dua kluster. Bentangkan jawapan anda dalam bentuk jadual.

With the assumptions made by John, determine the houses that belong to both the clusters. Present your answer in a table form.

(3 markah/marks)

c) Berdasarkan andaian John, manakah pusat kluster seterusnya?

Based on the assumption of John, where are the next cluster centers?

(2 markah/marks)

d) Daripada menggunakan pengelompokan K-Means, Caine mencadangkan untuk menggunakan pengelompokan hierarki bawah ke atas (aglomeratif). Untuk lebih tepat, Caine ingin melakukan pengelompokan satu pautan dengan mempertimbangkan jarak Euclidean antara objek.

Instead of using K-Means clustering, Caine suggests using a bottom-up (agglomerative) hierarchical clustering. To be more precise, Caine wants to perform a single-linkage clustering by considering Euclidean distance between objects.

Bantu Caine mencari 2 kelompok menggunakan algoritma yang diterangkan di atas.

Help Caine to find 2 clusters using the algorithm described above.

(4 markah/marks)

SOALAN 5/QUESTION 5

Terangkan dan jelaskan apakah itu paradigma Pembelajaran Terkukuh? Terangkan setiap komponen utama Pembelajaran Terkukuh seperti di bawah. Untuk setiap komponen berikan contoh komponen tersebut dengan berlatar belakang domain perdagangan kewangan.

Explain what is the Reinforcement Learning paradigm? Explain each of the key components of reinforcement learning (RL) below. For each of the components give an example of the components in the context of financial trading.

- a) Agen/Agent
- b) Persekitaran/Environment
- c) Aksi/Action
- d) Keadaan/States
- e) Balasan/Rewards
- f) Polisi/Policy

(10 markah/marks)

TAMAT
END